USER MANUAL

Azimuth Scribe

음성 녹음 · 음성 인식 · 로컬 AI 요약
사용자 매뉴얼

Version 1.0

2026년 10월 · 모든 처리는 사용자의 PC 안에서 이루어집니다

목차

1. 소개

2. 시스템 요구사항

3. 구성요소 설치와 다운로드

3.1 구성요소 한눈에 보기 · 3.2 Ollama · 3.3 Qwen 모델 · 3.4 Whisper 모델 · 3.5 GPU 가속(선택) · 3.6 체크리스트

4. 처음 실행하기

5. 화면 구성

6. 사용 방법

STEP 1 녹음 · STEP 2 파일 목록 · STEP 3 음성 인식 · STEP 4 요약 · 저장과 메뉴

7. 설정 화면

8. 요약 프롬프트 편집

9. 데이터 저장 위치

10. 문제 해결

11. 사용 시 유의사항

부록 A. 소스 코드로 실행하기

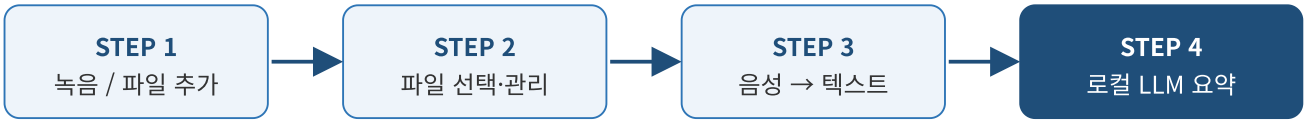
부록 B. 제3자 소프트웨어 고지

1. 소개

Azimuth Scribe는 회의, 상담, 진료 등 대화를 녹음하거나 기존 음성 파일을 불러와 **글로 옮기고(STT), 원하는 서식으로 요약**해 주는 데스크톱 프로그램입니다.

음성 인식은 **Whisper**(faster-whisper), 요약은 **Ollama**에서 실행되는 **Qwen** 계열 언어 모델이 담당하며, **둘 다 내 컴퓨터에서 직접 실행**됩니다. 녹음 내용과 요약 결과가 외부 서버로 전송되지 않으므로 민감한 내용을 다루는 업무에도 사용하기 좋습니다. (인터넷은 모델을 내려받을 때만 필요합니다.)

작업 흐름



주요 기능

- 마이크 녹음(16 kHz 모노 WAV) 및 기존 음성 파일 불러오기 (wav, mp3, m4a, flac, ogg, aac)
- 여러 파일을 한꺼번에 순서대로 음성 인식, 진행 중 중단 가능
- 업무 목적별 요약 프롬프트 선택 (일반 요약 / 회의록 / 진료 기록 / 법률 상담)
- 요약 결과를 실시간으로 확인하고, 클립보드 복사 또는 .txt / .md 파일로 저장
- GPU(NVIDIA CUDA)가 있으면 자동 활용, 없거나 오류가 나면 CPU로 자동 전환

2. 시스템 요구사항

항목	최소	권장
운영체제	Windows 10/11 64비트 (macOS, Linux는 소스 실행 시 사용 가능)	
메모리(RAM)	8 GB	16 GB 이상
저장 공간	약 10 GB 여유	20 GB 이상 (모델 추가 시)
GPU (선택)	없어도 동작(CPU)	VRAM 8 GB 이상 NVIDIA GPU (속도가 크게 향상)
마이크	녹음 기능 사용 시 필요 (파일만 불러올 때는 불필요)	
인터넷	최초 설치·모델 다운로드 시에만 필요	

참고
아래 용량·사양은 대략적인 값이며 모델 버전과 설정(컨텍스트 길이 등)에 따라 달라질 수 있습니다. CPU만으로도 동작하지만 긴 녹음의 음성 인식(large-v3)과 요약은 시간이 오래 걸립니다.

3. 구성요소 설치와 다운로드

3.1 구성요소 한눈에 보기

Azimuth Scribe를 사용하려면 **세 가지**가 준비되어야 합니다. 이 중 **Ollama와 요약 모델은 사용자가 직접 설치**해야 합니다.

구성요소	역할	준비 방법	비고
faster-whisper (Whisper 모델)	음성 → 텍스트 (STT)	프로그램에 포함 + 모델은 최초 실행 시 자동 다운로드	기본 모델 large-v3 (약 3 GB)
Ollama	로컬 LLM 실행 엔진	직접 설치 (3.2)	실행 중이어야 요약 가능
Qwen 모델	요약문 생성	`ollama pull` 로 다운로드 (3.3)	기본 `qwen3:4b-instruct` (약 2.5 GB)
NVIDIA 드라이버 / CUDA	GPU 가속 (선택)	직접 설치 (3.5)	없으면 CPU로 동작

> **Python 패키지는요?**
> faster-whisper, PyAV, NumPy, SciPy, sounddevice, Requests, PySide6 등은 배포본(설치 파일)에 이미 포함되어 있어 따로 설치할 필요가 없습니다. 소스 코드로 직접 실행하는 경우에만 부록 A를 참고하세요.

3.2 Ollama 설치

1. 웹 브라우저에서 **https://ollama.com/download** 에 접속해 Windows용 설치 파일(`OllamaSetup.exe`)을 내려받습니다.
2. 설치 파일을 실행하고 안내에 따라 설치합니다. 설치가 끝나면 Ollama가 자동으로 백그라운드(작업 표시줄 오른쪽 아래 트레이)에서 실행됩니다.
3. 설치 확인: 명령 프롬프트(또는 PowerShell)에서 아래 명령을 실행해 버전이 표시되면 정상입니다.

```
ollama --version
```

또는 브라우저 주소창에 `http://127.0.0.1:11434` 를 입력했을 때 *"Ollama is running"* 이라는 문구가 보이면 정상 실행 중입니다. Azimuth Scribe는 이 주소로 Ollama와 통신합니다.

> **팁**
> PC를 다시 시작한 뒤에는 Ollama가 실행 중인지 확인하세요. 시작 메뉴에서 Ollama를 실행하면 됩니다. 실행 중이 아니면 요약 시 "Ollama에 연결할 수 없습니다" 오류가 표시됩니다.

3.3 Qwen 요약 모델 다운로드

명령 프롬프트(또는 PowerShell)에서 아래 명령으로 기본 모델을 내려받습니다. 용량이 커서 몇 분 이상 걸릴 수 있습니다.

```
ollama pull qwen3:4b-instruct
```

다운로드가 끝나면 설치된 모델 목록을 확인합니다.

```
ollama list
```

모델 선택 가이드

모델 (예)	대략 용량	특징
`qwen3:1.7b`	약 1.4 GB	저사양 PC용. 빠르지만 긴 문서·복잡한 서식에서는 정확도가 낮을 수 있음
`qwen3:4b-instruct` **(기본)**	약 2.5 GB	속도와 품질의 균형. 대부분의 PC에서 권장
`qwen3:8b`	약 5 GB	더 높은 품질. 16 GB 이상 RAM 또는 8 GB 이상 VRAM 권장

다른 크기의 Qwen 모델도 같은 방식(`ollama pull 모델이름`)으로 받은 뒤, 프로그램의 **Settings → Preferences**에서 선택할 수 있습니다. 모델마다 라이선스가 다를 수 있으니 사용 전에 확인하세요.

> **참고**
> Qwen이 아닌 모델도 설정에서 직접 지정할 수 있으나(설정 화면의 "qwen 모델만 표시" 체크 해제), 이 프로그램의 기본 지시문과 한국어 결과는 Qwen3 계열에 맞춰 검증되었습니다.

3.4 Whisper(음성 인식) 모델

음성 인식 엔진(faster-whisper)은 프로그램에 포함되어 있고, **모델 파일은 최초 실행 시 인터넷에서 자동으로 내려받습니다.** 기본 모델은 **large-v3**(약 3 GB)이며, 한 번 받으면 PC에 저장되어 이후에는 인터넷 없이 사용할 수 있습니다.

모델	대략 용량	설명
`large-v3` **(기본)**	약 3 GB	가장 정확. GPU 권장, CPU에서는 느림
`medium`	약 1.5 GB	정확도와 속도의 절충
`small`	약 0.5 GB	빠르고 가벼움. 저사양 PC용
`base`	약 0.15 GB	매우 빠르지만 정확도 낮음. 테스트용

> **최초 실행 시 주의**
> 모델을 내려받는 동안 하단 상태 표시줄에 *"STT model loading..."* 이 표시되고 진행률 막대는 계속 움직이기만 합니다(다운로드 비율은 표시되지 않음). 인터넷 속도에 따라 수 분이 걸릴 수 있으니 창을 닫지 말고 기다려 주세요.

인터넷이 없는 PC에서 사용하기 (수동 다운로드)

1. 인터넷이 되는 PC에서 Hugging Face의 faster-whisper 변환 모델 저장소(예: **Systran/faster-whisper-large-v3**)에 접속해 *Files* 탭의 파일(`config.json`, `model.bin`, `tokenizer.json`, `vocabulary.json` 등 저장소의 모든 파일)을 내려받습니다.
2. 받은 파일들을 하나의 폴더(예: `D:\models\faster-whisper-large-v3`)에 모아 USB 등으로 대상 PC에 복사합니다.
3. 프로그램에서 **Settings → Preferences → 음성 인식 → 모델**의 **"폴더 선택..."** 버튼으로 해당 폴더를 지정하고 저장합니다.

3.5 GPU 가속 설정 (선택)

NVIDIA GPU가 없으면 이 절은 건너뛰어도 됩니다. 프로그램은 자동으로 CPU로 동작합니다.

대상	필요한 것
요약 (Ollama)	최신 **NVIDIA 그래픽 드라이버**만 설치되어 있으면 Ollama가 자동으로 GPU를 사용합니다.
음성 인식 (Whisper)	NVIDIA 드라이버에 더해 **CUDA 12**, **cuBLAS**, **cuDNN 9** 라이브러리가 필요합니다. NVIDIA 공식 사이트에서 설치하세요.

설치 후 **Settings → Preferences**의 "시스템 상태"에 *"● NVIDIA GPU 감지"* 가 초록색으로 표시되면 Whisper도 GPU를 사용할 수 있는 상태입니다. 노란색 경고가 나오면 CUDA 관련 라이브러리가 부족하다는 뜻이며, 이 경우에도 프로그램은 자동으로 CPU로 전환하여 정상 동작합니다.

3.6 설치 체크리스트

확인	항목
☐	Ollama를 설치했고 실행 중이다 (`ollama --version` 확인)
☐	`ollama pull qwen3:4b-instruct` 를 완료했다 (`ollama list` 에 표시됨)
☐	최초 실행 시 인터넷에 연결되어 있다 (Whisper 모델 다운로드) — 또는 모델 폴더를 미리 준비했다
☐	(녹음 사용 시) 마이크가 연결되어 있고 Windows의 마이크 접근이 허용되어 있다
☐	(GPU 사용 시) NVIDIA 드라이버, CUDA 12 / cuBLAS / cuDNN 9가 설치되어 있다

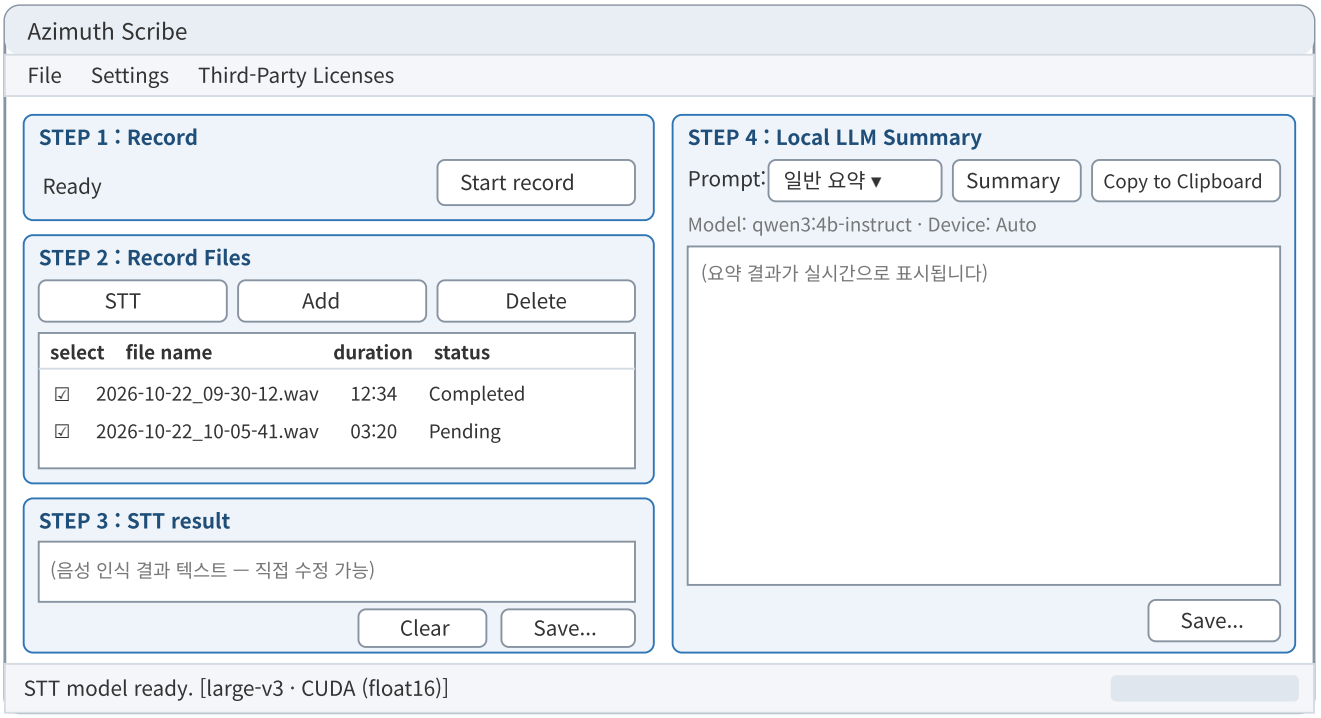
4. 처음 실행하기

1. **Ollama가 실행 중인지 확인**합니다 (트레이 아이콘 또는 3.2 절의 확인 방법).
2. **Azimuth Scribe를 실행**합니다. 창이 열리면 즉시 Whisper 모델 불러오기가 시작되며, **STT 버튼은 "STT model loading..."**으로 표시되고 **비활성화**됩니다.
3. 로딩이 끝나면 상태 표시줄에 *STT model ready. [large-v3 · CUDA (float16)]* 처럼 사용 중인 모델과 장치가 표시되고 STT 버튼이 활성화됩니다. 최초 실행에는 모델 다운로드로 수 분, 이후에는 수 초~수십 초가 걸립니다.
4. **Settings → Preferences**를 열어 상단 **시스템 상태**를 확인합니다. "● Ollama 연결됨"이 초록색이고 요약 모델이 목록에 보이면 준비가 끝난 것입니다.

> **로딩 중에는**
> 모델을 불러오는 동안, 그리고 음성 인식·요약이 진행되는 동안에는 **Preferences 메뉴가 비활성화**됩니다. 작업이 끝난 뒤 설정을 변경하세요. 반면 녹음과 파일 추가는 로딩 중에도 할 수 있습니다.

> **"STT model error"가 표시되면**
> 상태 표시줄에 오류 내용이 나타납니다. 대부분 (1) 최초 실행 시 인터넷 연결 없음, (2) 모델 이름/폴더 오류입니다. **Settings → Preferences**에서 모델을 변경하거나(예: `small`) 인터넷 연결 후 다시 시도하세요. 자세한 내용은 10장을 참고하세요.

5. 화면 구성



영역	설명
메뉴 막대	**File**: 결과 저장, Results / Recordings 폴더 열기 **Settings → Preferences**: 설정 화면 **Third-Party Licenses → License notice**: 제3자 소프트웨어 라이선스 고지
STEP 1 : Record	마이크 녹음 시작/종료 버튼과 녹음 상태 표시
STEP 2 : Record Files	음성 파일 목록(선택 체크, 파일명, 길이, 상태)과 **STT / Add / Delete** 버튼
STEP 3 : STT result	음성 인식 결과 텍스트. 직접 수정할 수 있으며 **Clear / Save...** 버튼 제공
STEP 4 : Local LLM Summary	프롬프트 선택, **Summary**(요약 실행), **Copy to Clipboard**, 사용 중인 모델·장치 표시, 요약 결과 창, **Save...**
상태 표시줄	하단 오른쪽. 현재 작업 상태와 진행률 막대, 오류 메시지가 표시됨

6. 사용 방법

STEP 1. 녹음하기

1. **Start record** 버튼을 누르면 녹음이 시작되고 왼쪽 문구가 *Recording...* 으로, 버튼이 **Stop record**로 바뀝니다.
2. 녹음을 마치려면 **Stop record**를 누릅니다. 파일 저장이 끝날 때까지 *Saving...* 이 표시되며, 끝나면 자동으로 STEP 2 목록에 추가(선택 상태)됩니다.

- 파일은 `2026-10-22_09-30-12.wav` 처럼 **녹음 시작 시각**을 이름으로 하여 **Recordings 폴더**에 저장됩니다. (9장)
- 음성 인식에 적합한 **16 kHz 모노**로 녹음됩니다.
- 녹음 중 마이크가 분리되면 그때까지의 내용은 저장하고 안내 메시지를 표시합니다.
- 마이크 오류 메시지가 나오면 마이크 연결과 운영체제의 마이크 접근 권한(Windows 설정 → 개인 정보 → 마이크)을 확인하세요.

> **좋은 인식 결과를 위한 팁**
> 조용한 환경에서 마이크를 화자 가까이에 두고, 여러 사람이 동시에 말하지 않도록 하면 정확도가 높아집니다.

STEP 2. 음성 파일 관리

버튼 / 항목	동작
Add	저장된 음성 파일(wav, mp3, m4a, flac, ogg, aac)을 선택해 목록에 추가합니다. 여러 개를 한 번에 선택할 수 있습니다.
Delete	**체크된 항목을 목록에서 제거**합니다. 디스크의 실제 파일은 삭제되지 않습니다. (음성 인식 중에는 사용할 수 없음)
select 열	체크한 파일만 음성 인식/삭제의 대상이 됩니다. 새로 추가된 파일은 기본적으로 체크됩니다.
duration 열	파일 길이(분:초). 읽을 수 없으면 "-"로 표시됩니다.
status 열	**Pending** 대기 · **Processing** 처리 중 · **Completed** 완료 · **Error** 오류

STEP 3. 음성 인식(STT)

1. 변환할 파일만 체크한 뒤 **STT** 버튼을 누릅니다. 체크된 파일이 없으면 "No file selected." 오류가 표시됩니다.
2. 파일이 **목록 순서대로 하나씩** 처리되며, 상태 표시줄에 *[파일명] processing... (1/3)* 처럼 진행 상황이 나타납니다.
3. 파일 하나가 끝날 때마다 결과가 **STEP 3 텍스트 창 끝에 이어 붙여지고** 상태가 Completed로 바뀝니다.

4. 진행 중에는 STT 버튼이 **Stop**으로 바뀝니다. 누르면 현재 구간(최대 약 30초 분량)까지 처리한 뒤 중단되며, **중단된 파일은 결과를 버리고 Pending으로 되돌아갑니다.** 남은 파일도 Pending으로 남습니다.

- 인식 언어는 **설정 → 음성 인식 → 언어**(기본: 한국어)를 따릅니다. 다른 언어 녹음이라면 먼저 설정을 바꾸세요.
- **Clear**는 텍스트 창의 내용을 모두 지웁니다. **Save...**는 텍스트를 파일로 저장합니다.
- 텍스트 창은 직접 편집할 수 있습니다. **오인식된 단어, 이름, 숫자를 요약 전에 바로잡으면** 요약 품질이 좋아집니다.

STEP 4. 로컬 LLM 요약

1. **Prompt** 목록에서 용도에 맞는 서식(일반 요약 / 회의록 / 진료 기록 / 법률 상담)을 고릅니다.
2. **Summary** 버튼을 누르면 STEP 3 텍스트 창의 내용을 요약합니다. 결과는 **생성되는 대로 실시간**으로 요약 창에 표시됩니다. 텍스트가 비어 있으면 "No STT result." 오류가 표시됩니다.
3. 진행 중에는 버튼이 **Stop**으로 바뀌며, 누르면 즉시 중단됩니다. 그때까지 생성된 내용은 요약 창에 남습니다.
4. 완료되면 **Copy to Clipboard**로 복사하거나 **Save...**로 파일에 저장합니다.

요약 영역의 *Model / Device* 줄에서 현재 사용 중인 모델과 장치를 확인할 수 있습니다.

"컨텍스트 길이 초과 가능" 대화상자가 나올 때

텍스트가 길어 현재 **컨텍스트 길이**(기본 8,192 토큰)를 넘을 것으로 예상되면 요약 전에 확인창이 표시됩니다. 넘치면 작성 지시가 담긴 앞부분이 잘려 엉뚱한 결과가 나올 수 있습니다.

선택	동작
늘려서 실행 (권장)	이번 한 번만 컨텍스트 길이를 필요한 만큼 늘려 실행합니다. 저장된 설정은 바뀌지 않습니다. 메모리 사용량이 늘고 첫 응답이 느려질 수 있습니다.
그대로 실행	현재 설정대로 실행합니다. 결과가 부정확할 수 있습니다.
취소	요약을 실행하지 않습니다.

추정 토큰 수가 처리 가능한 최대치(약 32,768 토큰)를 넘으면 **"Text too long"** 오류가 표시됩니다. 이때는 **녹음 파일별로 나누어** 또는 텍스트를 일부씩 잘라 요약하세요. 요약이 끝난 뒤 "Summary warning" 창이 나타나면 출력이 잘렸거나 컨텍스트를 거의 다 사용했다는 뜻이므로 결과를 반드시 확인하세요.

결과 저장과 File 메뉴

메뉴 / 버튼	동작
STEP 3의 **Save...** / File → **Save STT text...**	음성 인식 텍스트를 저장합니다. 기본 이름: `날짜_시간_stt.txt`
STEP 4의 **Save...** / File → **Save summary...**	요약문을 저장합니다. 기본 이름: `날짜_시간_summary_프롬프트이름.txt`

File → **Open Results folder**	저장 결과 기본 폴더를 탐색기로 엽니다.
File → **Open Recordings folder**	녹음 파일 폴더를 탐색기로 엽니다.

저장 대화상자에서 **.txt** 또는 **.md(Markdown)** 형식을 선택할 수 있으며, 내용이 비어 있으면 저장되지 않고 안내가 표시됩니다.

> **종료 시 주의**
> STEP 3·4의 텍스트는 프로그램을 닫으면 사라집니다. 필요한 결과는 종료 전에 반드시 저장하세요. (녹음 파일은 Recordings 폴더에 남습니다.)

7. 설정 화면

Settings → Preferences에서 엽니다. 변경 내용은 **저장**을 눌러야 적용되며 **취소**를 누르면 버려집니다.

시스템 상태

Ollama 연결 여부와 설치된 모델 수, GPU 감지 결과, 현재 메모리에 올라간 모델과 실행 위치(GPU/CPU)를 보여줍니다. 상태가 바뀌었다면 **새로고침**을 누르세요.

표시	의미
● Ollama 연결됨	정상. 요약 가능
● Ollama에 연결할 수 없습니다	Ollama가 설치/실행되지 않음 (3.2 참고)
● NVIDIA GPU 감지	Whisper GPU 사용 가능
● GPU 감지 (CUDA 사용 불가)	GPU는 있으나 CUDA 12 / cuBLAS / cuDNN 9 미설치 → CPU로 동작

요약 모델 (Ollama)

항목	선택지 / 범위	설명
모델	설치된 모델 목록	"qwen 모델만 표시"를 해제하면 모든 모델이 표시됩니다. 설치되지 않은 모델을 저장하려 하면 확인창이 나타납니다.
실행 장치	자동(권장) / CPU만 / GPU 우선	자동: Ollama가 VRAM을 감지해 알아서 분배. CPU만: GPU 오류 시 가장 안전. GPU 우선: VRAM 부족 시 오류나 속도 저하 가능
컨텍스트 길이	2,048 ~ 65,536 (기본 8,192)	한 번에 처리할 최대 토큰. 긴 상담은 늘려야 하지만 메모리를 더 사용함
최대 출력 토큰	256 ~ 16,384 (기본 2,048)	요약문의 최대 길이. 결과가 중간에 잘리면 늘리세요.
온도	0.0 ~ 1.0 (기본 0.2)	낮을수록 일관되고 원문에 충실, 높을수록 다양한 표현. 기록 정리에는 낮은 값을 권장

음성 인식 (Whisper)

항목	선택지	설명
모델	large-v3 / medium / small / base 또는 폴더 경로	직접 입력하거나 "폴더 선택..."으로 수동 다운로드한 모델 폴더를 지정

실행 장치	자동 / CPU / GPU (NVIDIA CUDA)	GPU 로딩·실행에 실패하면 자동으로 CPU로 전환됨
연산 방식	자동 / int8 / int8_float16 / float16	자동: GPU는 float16, CPU는 int8. 보통 **자동**이면 충분
언어	한국어 / 영어 / 일본어 / 중국어 / 자동 감지	녹음 언어와 맞춰야 정확도가 높음. 여러 언어가 섞이면 자동 감지

저장 후 동작
음성 인식 설정을 바꾸면 저장 후 **Whisper 모델을 다시 불러옵니다**(수 초~수 분). LLM 모델·장치를 바꾸면 이전 모델이 메모리(VRAM)에서 자동으로 내려갑니다. 변경하지 않았다면 상태 표시줄에 "Settings saved."만 표시됩니다.

8. 요약 프롬프트 편집

기본으로 **일반 요약, 회의록, 진료 기록, 법률 상담** 네 가지 프롬프트가 제공됩니다. 프로그램 안에는 프롬프트 편집 화면이 없으며, **prompts.json** 파일을 메모장 등 텍스트 편집기로 직접 수정해 추가·변경합니다.

1. **프로그램을 종료**합니다. (실행 중 수정하면 프로그램이 다시 저장할 때 덮어쓸 수 있습니다.)
2. `%APPDATA%\Azimuth_Scribe\prompts.json` 을 텍스트 편집기(UTF-8)로 엽니다. (탐색기 주소창에 `%APPDATA%\Azimuth_Scribe` 를 입력하면 바로 이동)
3. 아래 형식으로 항목을 추가하거나 수정하고 저장한 뒤 프로그램을 다시 실행합니다. 줄바꿈은 `\n` 으로 씁니다.

```
{
    "일반 요약": "다음 내용을 핵심 내용 중심으로 요약하세요.\n\n1. 주요 내용\n2. 중요한 사실\n...",
    "고객 응대 기록": "다음 통화 내용을 정리하세요.\n\n1. 문의 내용\n2. 안내한 내용\n3. 후속 조치\n\n원문에 없는 내용을 추가하지 마세요."
}
```

좋은 프롬프트 작성 요령

- 출력할 **항목을 번호로 명시**하세요 (예: 1. 주요 내용 2. 결정사항 …).
- **"원문에 없는 내용을 추가하지 마세요"** 같은 문장을 포함하면 지어내는 내용을 줄일 수 있습니다.
- 프로그램은 모든 프롬프트 앞에 "원문에 있는 정보만 사용, 추측·진단 금지, 한국어로 결과만 출력" 같은 공통 규칙을 자동으로 붙입니다.

> **참고**
> 파일이 손상되어 읽을 수 없으면 프로그램이 손상된 파일을 `prompts.json.corrupt-날짜-시간` 이름으로 보관하고 기본 프롬프트로 다시 만듭니다. 기본값으로 되돌리고 싶다면 prompts.json을 삭제(또는 이름 변경)한 뒤 실행하세요.

9. 데이터 저장 위치

모든 사용자 데이터는 실행 위치나 설치 위치와 무관하게 **항상 같은 폴더**에 저장됩니다.

운영체제	폴더
Windows	`%APPDATA%\Azimuth_Scribe` (예: C:\Users\사용자이름\AppData\Roaming\Azimuth_Scribe)
macOS	`~/Library/Application Support/Azimuth_Scribe`
Linux	`~/.local/share/Azimuth_Scribe`

항목	내용
`settings.json`	모델·장치·언어 등 설정
`prompts.json`	요약 프롬프트
`Recordings\`	녹음한 WAV 파일
`Results\`	저장 대화상자의 기본 위치(저장한 텍스트·요약)

그 밖에 모델 파일은 각 도구의 기본 위치에 저장됩니다.

- Ollama 모델: `C:\Users\사용자이름\.ollama\models`
- Whisper 모델(자동 다운로드): `C:\Users\사용자이름\.cache\huggingface\hub`

> **백업·이전**
> 다른 PC로 옮길 때는 `Azimuth_Scribe` 폴더를 복사하면 설정과 프롬프트, 녹음이 함께 옮겨집니다. 녹음에는 민감한 내용이 있을 수 있으니 불필요한 파일은 직접 삭제해 관리하세요.

10. 문제 해결

증상 / 메시지	원인과 해결
STT 버튼이 계속 "STT model loading..."	최초 실행 시 모델(약 3 GB) 다운로드 중일 수 있습니다. 인터넷 연결을 확인하고 기다리세요. 너무 오래 걸리면 Whisper 모델을 small/medium으로 바꾸세요.
"STT model error"	상태 표시줄의 오류를 확인하세요. 인터넷 없음 → 연결 후 재시도 또는 모델 폴더 수동 지정(3.4). 모델 이름/경로 오류 → Preferences에서 수정. 오류 후에도 Preferences는 열 수 있습니다.
"Ollama에 연결할 수 없습니다"	Ollama가 실행 중이 아닙니다. 시작 메뉴에서 Ollama를 실행하고 `http://127.0.0.1:11434` 접속을 확인하세요. 방화벽/보안 프로그램이 localhost 통신을 막지 않는지도 확인합니다.
"Ollama 오류 … 모델이 설치되어 있는지 확인"	설정한 모델이 설치되지 않았습니다. `ollama pull 모델이름` 후 Preferences에서 해당 모델을 선택하세요.
"LLM 응답 시간이 초과되었습니다"	첫 응답에서 모델 로딩과 긴 입력 처리 시간이 오래 걸린 경우입니다. 더 작은 모델 사용, 컨텍스트 길이 축소, GPU 사용을 고려하세요.
"LLM이 빈 응답을 반환했습니다"	다시 시도하세요. 반복되면 모델을 바꾸거나 입력 텍스트를 확인하세요.
요약이 중간에 끊김 / 경고창	최대 출력 토큰 또는 컨텍스트 길이 부족입니다. Preferences에서 값을 늘리거나 텍스트를 나누어 요약하세요.
"Text too long"	입력이 처리 한계(약 32,768 토큰)를 넘었습니다. 파일별로 나누어 요약하세요.
Preferences 메뉴가 회색으로 비활성화	모델 로딩, 음성 인식, 요약 중에는 설정을 열 수 없습니다. 작업이 끝날 때까지 기다리거나 Stop으로 중단하세요.
녹음 오류 / "녹음된 데이터가 없습니다"	마이크 연결, 기본 입력 장치, 운영체제의 마이크 접근 권한(Windows: 설정 → 개인 정보 및 보안 → 마이크)을 확인하세요.
GPU로 인식이 안 됨 / 느림	시스템 상태의 GPU 표시를 확인하세요. 노란색이면 CUDA 12 / cuBLAS / cuDNN 9를 설치해야 합니다. 설치 전에는 자동으로 CPU로 동작합니다.
GPU 메모리 부족 오류	요약 실행 장치를 "자동" 또는 "CPU만"으로 바꾸거나 더 작은 모델을 사용하세요. Whisper는 연산 방식을 int8_float16 또는 int8로 바꾸면 VRAM이 절약됩니다.
음성 파일의 길이가 "-"로 표시	길이 정보를 읽지 못한 것으로, 음성 인식 자체는 가능한 경우가 많습니다. 인식이 실패(Error)하면 파일이 손상되었거나 지원하지 않는 형식일 수 있으니 WAV/MP3로 변환해 보세요.
인식 결과가 엉뚱함 / 다른 언어로 나옴	Preferences의 **언어** 설정이 녹음 언어와 같은지 확인하세요. 소음이 많으면 모델을 large-v3로 올리면 개선될 수 있습니다.

11. 사용 시 유의사항

- **결과는 반드시 검토하세요.** 음성 인식과 AI 요약에는 오류(오인식, 누락, 잘못된 요약)가 있을 수 있습니다. 특히 이름, 숫자, 날짜, 약 이름 등은 원본과 대조하세요.
- **진료 기록·법률 상담 프롬프트는 기록 정리를 돕는 도구입니다.** 진단이나 법률적 판단을 대신하지 않으며, 최종 기록의 책임은 사용자(전문가)에게 있습니다.
- **녹음에 대한 동의**: 대화를 녹음하기 전에 참석자(환자, 의뢰인 등)에게 알리고 동의를 받는 등 관련 법령과 소속 기관의 규정을 지켜 주세요.
- **개인정보 보호**: 이 프로그램은 내용을 외부로 전송하지 않지만, 녹음 파일과 저장된 결과는 PC에 남습니다. 컴퓨터 접근 권한 관리와 불필요한 파일 삭제는 사용자 몫입니다.
- **저작권·라이선스**: 사용하는 모델마다 라이선스 조건이 다를 수 있습니다. 상업적으로 사용할 때는 각 모델의 라이선스를 확인하세요.

부록 A. 소스 코드로 실행하기

배포본(설치 파일) 대신 소스 코드(`main.py`)로 직접 실행하는 개발자·고급 사용자용 안내입니다. Python 3.10 이상을 권장합니다.

```
pip install PySide6 faster-whisper sounddevice numpy scipy requests
python main.py
```

- faster-whisper를 설치하면 PyAV와 CTranslate2가 함께 설치됩니다.
- 아이콘 파일(`Azimuth_logo.png`, `settings_24dp.png`)을 `main.py`와 같은 폴더에 두세요. 없어도 동작하지만 아이콘이 표시되지 않습니다.
- Ollama와 요약 모델, Whisper 모델은 3장과 동일하게 준비합니다.
- Python 3.14 등 매우 최신 버전은 일부 패키지가 아직 지원하지 않을 수 있습니다.

부록 B. 제3자 소프트웨어 고지

Azimuth Scribe는 다음 오픈소스 소프트웨어를 사용합니다. 각 구성요소는 고유의 저작권 및 라이선스 조건을 따릅니다. 프로그램에서도 **Third-Party Licenses → License notice** 메뉴로 확인할 수 있습니다.

구성요소	라이선스	용도
PySide6 (Qt for Python)	LGPL v3 등	사용자 인터페이스
faster-whisper	MIT	음성 인식 엔진
CTranslate2	MIT	추론 엔진
OpenAI Whisper (모델 가중치)	MIT	음성 인식 모델
PyAV / FFmpeg	BSD-3-Clause / LGPL·GPL(빌드에 따라)	오디오 디코딩, 길이 확인
NumPy, SciPy	BSD-3-Clause	수치 처리, WAV 저장
python-sounddevice / PortAudio	MIT	마이크 녹음
Requests	Apache-2.0	Ollama와 통신

별도로 설치하여 사용하는 구성요소 (프로그램에 포함되지 않음)

구성요소	라이선스	비고
Ollama	MIT	로컬 LLM 실행 환경
Qwen3 모델	Apache-2.0 (모델마다 다를 수 있음)	사용하는 모델의 라이선스를 확인하세요

Azimuth Scribe 1.0 사용자 매뉴얼 · 이 문서의 모델 용량과 요구사양은 대략적인 값이며, 외부 도구(Ollama, Hugging Face 등)의 화면·절차는 변경될 수 있습니다.